



Actividad Bonus

ReMatch

Entrega

- **Lugar:** Repositorio personal de GitHub — Carpeta: Actividades/ACBonus
- **Fecha máxima de entrega:** 18 de Junio 17:20
- **Ejecución de actividad:** La Actividad será ejecutada **únicamente** desde la terminal del computador. Los *paths* relativos utilizados en la Actividad deben ser coherentes con esta instrucción, y no pueden modificarse.

Importante: Antes de comenzar, comprueba que Git este funcionando correctamente en tu repositorio privado. Para esto, **sube los archivos base de la actividad de inmediato** (*add*, *commit*, *push*). Se espera que en esta actividad (así como en las demás actividades y tareas) utilices Git a lo largo de **todo tu desarrollo** como una herramienta, no sólo como un método de entrega. Es por esto que recomendamos enfáticamente que vayas subiendo tus cambios constantemente (*push*), ya que **problemas de último minuto** relacionados con la entrega y Git **no serán considerados**.

Preamble

En esta actividad analizaremos el contenido de las páginas de Wikipedia a través de las herramientas que nos da la librería `REmatch`.

Primero extraemos el contenido de una página de Wikipedia, usando la librería de Python `wikipedia` que nos permite acceder páginas de Wikipedia a través de una API. A continuación, accederemos la página de Wikipedia sobre Chile (en inglés).

```
pip3 install --upgrade wikipedia pyrematch
```

```
1 import wikipedia
2 text = wikipedia.page("Chile", auto_suggest=False).content
3
4 # Imprimir los primeros 4000 caracteres
5 print(text[:4000], '...')
```

Ahora en la variable `text` tenemos el contenido de la página de Wikipedia correspondiente a Chile (versión inglés), sin los comandos de HTML que aparecen en la versión `source` de la página (adicionalmente, esta versión textual tampoco contiene los links ni los infoboxes de Wikipedia). Efectivamente, esto es la versión textual de la página que contiene todas las secciones, subsecciones, y subsubsecciones (incluso más subsi es necesario) de la página, junto con el texto que contienen estos elementos.

En este formato, para especificar una sección basta con colocar `"== Nombre sección =="` en una sola línea del texto. Aquí es importante observar que entre el último `"=` y el nombre de la sección hay un

espacio, y similarmente al final del nombre hay un espacio antes del `"=`". Hecho que esto se especifica en una línea de texto, sin ningún carácter más, será importante para definir nuestras consultas para extraer información. Similarmente, la subsección se especifica con `"=== Nombre subsección ==="`, y delimitador para la subsubsección contiene cuatro símbolos `"=`", quiere decir `"==== Nombre subsubsección =====`".

Esta actividad

En esta actividad usted usará la librería `REmatch` para extraer contenido como secciones y subsecciones de una página de wikipedia. Esta actividad está dividida en seis consultas que usted debe resolver. Para todas las consultas es necesario definir una consulta `REQL`, compilarlo en `REmatch`, y iterar sobre sus resultados obtenidos a través de un `query.findIter(text)`, cómo ya se explico en los contenidos. Allá también mostramos como acceder el contenido y la posición de un match. Por último, para cada consulta se darán algunos resultados para mostrar el resultado esperado.

Puedes encontrar los mismos contenidos de la página de wikipedia de Chile en [este link](#)

Archivos

El archivo `download_wiki.py` permite descargar el contenido de una página de wikipedia en ingles y guardarla en un archivo. La librería `wikipedia` a veces falla por lo que es mejor trabajar desde un archivo. El modo de uso es:

```
python3 download_wiki.py "<nombre_wikipedia>"
```

Por ejemplo para bajar el contenido de wikipedia de Chile usa

```
python3 download_wiki.py "Chile"
```

Debes completar las consultas en `consultas.py`. Puedes ejecutar el programa usando:

```
python3 consultas.py "<nombre_wikipedia>"
```

siempre y cuando el contenido haya sido descargado anteriormente.

Consultas

Cada consulta recibe como input el texto de la página de wikipedia a analizar y retorna como output una lista con strings. Completa las consultas según lo pedido en cada una y retorna cada línea del output como un elemento de la lista.

Consulta 1

Por algo hemos explicado cómo se identifican las secciones y sub(sub)?secciones. En esta primera consulta, buscamos obtener todos los títulos de secciones del documento y la posición donde aparecen (su span).

Para todas las consultas es necesario definir una consulta REQL, compilarlo en REmatch, y iterar sobre sus resultados obtenidos a través de un `query.findIter(text)`. Ahí también mostramos como acceder el contenido y la posición de un match.

Los resultados en el caso de la página de Chile son:

- Título: 'Etymology' - Posición: (2782, 2791)
- Título: 'History' - Posición: (4149, 4156)
- Título: 'Geography' - Posición: (28554, 28563)
- Título: 'Government and politics' - Posición: (40629, 40652)
- Título: 'Economy' - Posición: (51478, 51485)
- Título: 'Demographics' - Posición: (67082, 67094)
- Título: 'Culture' - Posición: (80316, 80323)
- Título: 'See also' - Posición: (89291, 89299)
- Título: 'References' - Posición: (89326, 89336)
- Título: 'Further reading' - Posición: (89381, 89396)
- Título: 'External links' - Posición: (89405, 89419)

Consulta 2

Ahora vamos un nivel más abajo, y pedimos obtener todos los títulos de subsecciones del documento y las posiciones donde aparecen (su span).

Algunos de los resultados son, entre otros:

- Subtítulo: 'Early history' - Posición: (4166, 4179)
- Subtítulo: 'Mapuche' - Posición: (5049, 5056)
- Subtítulo: 'Spanish colonization' - Posición: (6154, 6174)
- Subtítulo: 'Independence and nation building' - Posición: (9935, 9967)
- Subtítulo: '20th century' - Posición: (15410, 15422)
- Subtítulo: '21st century' - Posición: (24266, 24278)
- Subtítulo: 'Topography' - Posición: (30931, 30941)

Consulta 3

Ahora vamos aún más adentro de una subsección, y buscamos encontrar cada subsubsección del documento y su contenido, imprimiendo el subsubtítulo y su contenido.

En cambio a otras consultas, aquí nos interesa el contenido de la subsubsección; quiere decir, el texto qué aparece en esta subsubsección, y qué termina con el inicio de la siguiente sección, subsección o subsubsección. Dado que el contenido puede ser muy extenso, solo imprimiremos la posición donde aparece, esto es, el span del contenido.

Puedes asumir que no existe el caracter "=" en el contenido de la subsubsección.

El único resultado en este caso sería:

- Subsubtítulo: 'Pinochet era (1973-1990)' - Posición: (21128, 24261)

Consulta 4

Ahora buscamos encontrar cada sección del documento que NO tenga una subsección, imprimiendo el título y su contenido (nuevamente, su span).

Nota: Cuando un título no tiene subtítulo, la siguiente sección es otro título o el fin del archivo.

Algunos resultados en este caso serían:

- Título: 'Etymology' - Posición: (2782, 2791)
- Título: 'See also' - Posición: (89291, 89299)

Consulta 5

Esta consulta es bien parecida a la consulta 3, pero ahora buscamos encontrar cada subsección del documento y extraer su contenido, imprimiendo el subtítulo y su contenido. Efectivamente, estamos un nivel más alto que en la consulta 3.

El contenido de la subsección debe incluir también las subsubsecciones que tenga.

Algunos resultados de ejemplo para nuestro texto serían:

- Subtítulo: 'Early history' - Posición: (4166, 4179)
- Subtítulo: 'Mapuche' - Posición: (5049, 5056)
- Subtítulo: 'Spanish colonization' - Posición: (6154, 6174)
- Subtítulo: 'Independence and nation building' - Posición: (9935, 9967)
- Subtítulo: '20th century' - Posición: (15410, 15422)
- Subtítulo: '21st century' - Posición: (24266, 24278)

Consulta 6

Finalmente, en esta consulta buscamos encontrar cada subsección del documento que tenga al menos una subsubsección y extraer su contenido, imprimiendo el subtítulo y su contenido (el contenido del subtítulo incluye al subsubtítulo y su contenido).

El único resultado en este caso sería:

- Subtítulo: '20th century' - Posición: (15410, 15422)

Entrega

Para su solución, usted debe subir un archivo llamado `consultas.py` con las funciones de consultas implementadas correctamente.

El output esperado del programa `consultas.py` al ejecutar el comando `python3 consultas.py "Chile"` es:

```
# Consulta 1
- Título: 'Etymology' - Posición: (2782, 2791)
- Título: 'History' - Posición: (4149, 4156)
- Título: 'Geography' - Posición: (28554, 28563)
- Título: 'Government and politics' - Posición: (40629, 40652)
- Título: 'Economy' - Posición: (51478, 51485)
- Título: 'Demographics' - Posición: (67082, 67094)
- Título: 'Culture' - Posición: (80316, 80323)
- Título: 'See also' - Posición: (89291, 89299)
- Título: 'References' - Posición: (89326, 89336)
- Título: 'Further reading' - Posición: (89381, 89396)
- Título: 'External links' - Posición: (89405, 89419)

# Consulta 2
- Subtítulo: 'Early history' - Posición: (4166, 4179)
- Subtítulo: 'Mapuche' - Posición: (5049, 5056)
- Subtítulo: 'Spanish colonization' - Posición: (6154, 6174)
- Subtítulo: 'Independence and nation building' - Posición: (9935, 9967)
- Subtítulo: '20th century' - Posición: (15410, 15422)
- Subtítulo: '21st century' - Posición: (24266, 24278)
- Subtítulo: 'Topography' - Posición: (30931, 30941)
- Subtítulo: 'Climate and hydrography' - Posición: (35504, 35527)
- Subtítulo: 'Biodiversity' - Posición: (37356, 37368)
- Subtítulo: 'Administrative divisions' - Posición: (44465, 44489)
- Subtítulo: 'Foreign relations' - Posición: (45186, 45203)
- Subtítulo: 'Military' - Posición: (48113, 48121)
- Subtítulo: 'National symbols' - Posición: (50466, 50482)
- Subtítulo: 'Mineral resources' - Posición: (56452, 56469)
- Subtítulo: 'Agriculture' - Posición: (57570, 57581)
- Subtítulo: 'Tourism' - Posición: (59139, 59146)
- Subtítulo: 'Transport' - Posición: (62228, 62237)
- Subtítulo: 'Internet and telecommunications' - Posición: (64243, 64274)
- Subtítulo: 'Energy' - Posición: (65443, 65449)
- Subtítulo: 'Urbanization' - Posición: (67346, 67358)
- Subtítulo: 'Ancestry and ethnicity' - Posición: (67639, 67661)
- Subtítulo: 'Languages' - Posición: (72616, 72625)
- Subtítulo: 'Religion' - Posición: (74230, 74238)
- Subtítulo: 'Education' - Posición: (77846, 77855)
- Subtítulo: 'Health' - Posición: (79408, 79414)
- Subtítulo: 'Cultural heritage' - Posición: (81158, 81175)
- Subtítulo: 'Music and dance' - Posición: (82278, 82293)
- Subtítulo: 'Literature' - Posición: (83616, 83626)
- Subtítulo: 'Folklore' - Posición: (84660, 84668)
```

- Subtítulo: 'Cuisine' - Posición: (85310, 85317)
- Subtítulo: 'Sports' - Posición: (86039, 86045)
- Subtítulo: 'Notes' - Posición: (89346, 89351)
- Subtítulo: 'Citations' - Posición: (89362, 89371)

Consulta 3

- Subsubtítulo: 'Pinochet era (1973-1990)' - Posición: (21128, 24261)

Consulta 4

- Título: 'Etymology' - Posición: (2795, 4145)
- Título: 'See also' - Posición: (89303, 89322)
- Título: 'Further reading' - Posición: (89400, 89401)
- Título: 'External links' - Posición: (89423, 89903)

Consulta 5

- Subtítulo: 'Early history' - Posición: (4184, 5044)
- Subtítulo: 'Mapuche' - Posición: (5061, 6149)
- Subtítulo: 'Spanish colonization' - Posición: (6179, 9930)
- Subtítulo: 'Independence and nation building' - Posición: (9972, 15405)
- Subtítulo: '20th century' - Posición: (15427, 24261)
- Subtítulo: '21st century' - Posición: (24283, 28550)
- Subtítulo: 'Topography' - Posición: (30946, 35499)
- Subtítulo: 'Climate and hydrography' - Posición: (35532, 37351)
- Subtítulo: 'Biodiversity' - Posición: (37373, 40625)
- Subtítulo: 'Administrative divisions' - Posición: (44494, 45181)
- Subtítulo: 'Foreign relations' - Posición: (45208, 48108)
- Subtítulo: 'Military' - Posición: (48126, 50461)
- Subtítulo: 'National symbols' - Posición: (50487, 51474)
- Subtítulo: 'Mineral resources' - Posición: (56474, 57565)
- Subtítulo: 'Agriculture' - Posición: (57586, 59134)
- Subtítulo: 'Tourism' - Posición: (59151, 62223)
- Subtítulo: 'Transport' - Posición: (62242, 64238)
- Subtítulo: 'Internet and telecommunications' - Posición: (64279, 65438)
- Subtítulo: 'Energy' - Posición: (65454, 67078)
- Subtítulo: 'Urbanization' - Posición: (67363, 67634)
- Subtítulo: 'Ancestry and ethnicity' - Posición: (67666, 72611)
- Subtítulo: 'Languages' - Posición: (72630, 74225)
- Subtítulo: 'Religion' - Posición: (74243, 77841)
- Subtítulo: 'Education' - Posición: (77860, 79403)
- Subtítulo: 'Health' - Posición: (79419, 80312)
- Subtítulo: 'Cultural heritage' - Posición: (81180, 82273)
- Subtítulo: 'Music and dance' - Posición: (82298, 83611)
- Subtítulo: 'Literature' - Posición: (83631, 84655)
- Subtítulo: 'Folklore' - Posición: (84673, 85305)
- Subtítulo: 'Cuisine' - Posición: (85322, 86034)
- Subtítulo: 'Sports' - Posición: (86050, 89287)
- Subtítulo: 'Notes' - Posición: (89356, 89357)
- Subtítulo: 'Citations' - Posición: (89376, 89377)

Consulta 6

- Subsubtítulo: '20th century' - Posición: (15427, 24261)

Notas

- No puedes hacer *import* de otras librerías externas a las entregadas en el archivo.
- Tu actividad será evaluada usando tus archivo modificado `consultas.py`
- Recuerda que la ubicación de tu entrega es en **tu repositorio de Git**. En la rama (*branch*) por defecto del repositorio: `main`.
- Recuerda que esta evaluación presenta corrección **automatizada**. Si entregas un código que se cae al momento de correr los *tests*, será evaluado con 0 puntos.

Ejecución de *tests*

En esta actividad se provee el archivo `tests_consultas.py` el cual contiene diferentes *tests* que ayudan a validar el desarrollo de la actividad. Para ejecutar estos *tests*, **primero debes posicionar tu terminal/console en la carpeta de la actividad (Actividades/ACBonus)**. Luego, desde esta misma, debes escribir el siguiente comando para ejecutar todos los *tests* de la actividad:

```
python3 -m unittest discover tests_publicos -v -b
```

Existe una clase de test por cada parte del enunciado. Si quieres testear ejecutar una consulta en particular, puedes hacer usando el comando:

```
python3 -m unittest -v -b tests_publicos.tests_consultas.<NombreClase>
```

Por ejemplo, si quieres testear la parte 1:

```
python -m unittest -v -b tests_publicos.tests_consultas.VerificarConsulta1
```

Importante: recuerda que si `python3` no funciona, probar con el comando específico de tu computador. Este puede ser `py`, `python`, `py3` o `python3.12`.